Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates

Leslie N. Smith Nicholay Topin

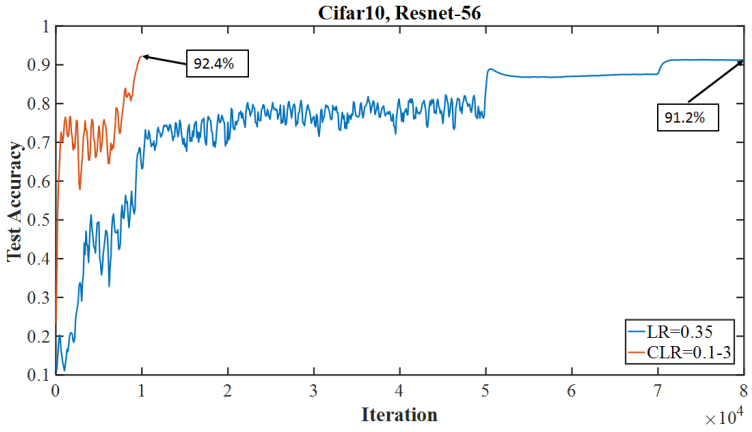
arXiv:1708.07120v3 2018

Learning rate: размер шага обучения

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$$

- θ — веса сети, L — функция потерь, η — learning rate. Градиент ∇L определяет направление изменения ошибки.
- При фиксированном градиенте изменение весов пропорционально η. Чрезмерный LR может приводить к неустойчивости обучения.
- Стандартный режим: ступенчатое снижение LR.
  Super-convergence: цикл с повышением и снижением LR.

CIFAR-10: сравнение режимов обучения



Ступенчатый LR

≈ 80 000 итераций
91.2% test accuracy

CLR 0.1–3.0

10 000 итераций
92.4% test accuracy

Примерно в 8 раз меньше итераций и на 1.2 п.п. выше точность.

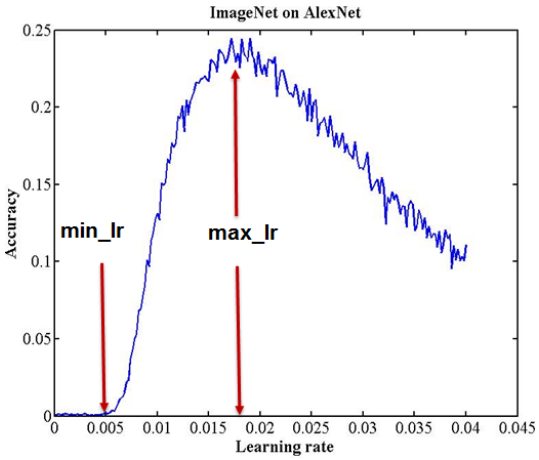
1cycle: один подъём и одно снижение LR

1. **Подъём LR до выбранного максимума.**
   При фиксированном градиенте изменение весов пропорционально LR. Большой LR в середине цикла усиливает регуляризацию.

2. **Снижение LR до нижней границы.**
   Цикл завершается до окончания обучения. Оставшиеся итерации используют дальнейшее снижение LR.

3. **Заключительное снижение LR.**
   LR снижается на несколько порядков ниже начального значения. Заключительная фаза предназначена для сходимости.

Определение границ LR: LR range test

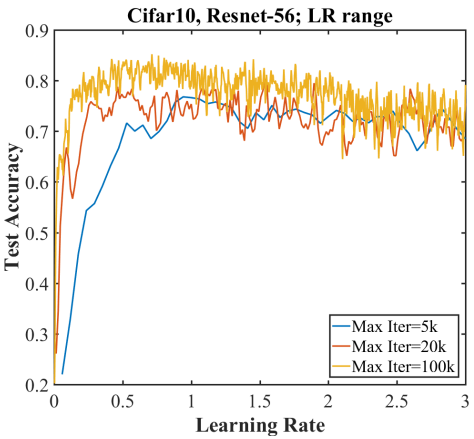


Предварительный запуск: линейное увеличение LR.

В начальном диапазоне accuracy повышается. После пика accuracy снижается.

LR при пике accuracy задаёт верхнюю границу CLR. Нижняя может быть в 3–4 раза меньше.

LR range test: CIFAR-10 / ResNet-56

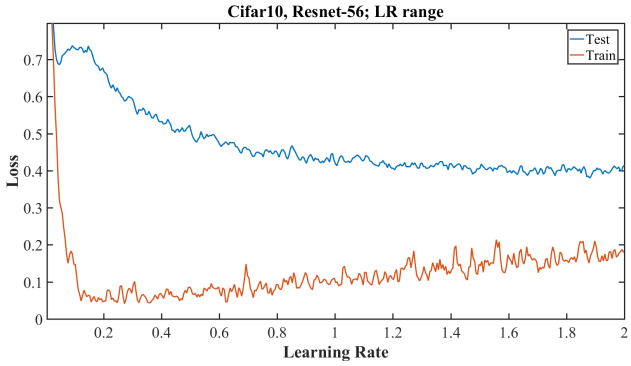


CIFAR-10 / ResNet-56:
accuracy остаётся высокой при LR вплоть до 3.0.

Кривые соответствуют тестам длительностью 5, 20 и 100 тысяч итераций. Их поведение сходно.

Авторы рассматривают результат как возможный признак super-convergence.

Регуляризация большим LR



При LR 0.3–1.5

Обучающая выборка: функция потерь растёт.

Тестовая выборка: функция потерь снижается.

Авторы связывают это с регуляризацией.

При увеличении LR обучающая ошибка возрастает, а тестовая ошибка уменьшается.

Баланс регуляризации

Настройка	**Влияние на обучение**
Weight decay	Штрафует большие веса. В опытах на ImageNet авторы уменьшают его для большого LR.
Dropout	Случайное исключение элементов сети. Фактор регуляризации, учитываемый вместе с LR.
Размер батча	Меньший батч увеличивает шум оценки градиента. Размер батча учитывается при выборе LR.

Большой LR требует согласования с остальными факторами регуляризации. Параметры зависят от архитектуры и данных.

Шум обновлений и обобщение

- SGD использует оценку градиента по батчу. Увеличение LR повышает амплитуду шума обновлений.
- Авторы связывают этот шум с регуляризацией и поиском более плоских областей функции потерь.
- Плоская область характеризуется слабым изменением loss при малых возмущениях весов.
- Заключительное снижение LR предназначено для сходимости.

Обучение на сокращённой выборке

Train примеров	**Ступенчатый LR, %**	**CLR, %**
40 000	89.1	91.1
20 000	82.7	87.9
10 000	71.4	80.6

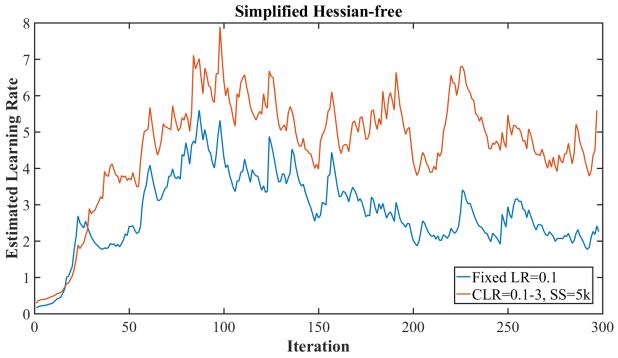
Преимущество CLR: 2.0, 5.2 и 9.2 процентного пункта.

Ступенчатый LR: 80 000 итераций. CLR: 10 000.

Результаты на MNIST, CIFAR-100 и ImageNet

Данные / модель	**Стандартный режим**	**1cycle**
MNIST / LeNet	$99.03 \pm 0.04\%$ 85 эпох	$99.25 \pm 0.03\%$ 12 эпох
CIFAR-100 / ResNet-56	$60.8 \pm 0.4\%$ 100 эпох	$65.4 \pm 0.2\%$ 25 эпох
ImageNet / Inception-ResNet-v2	67.6% 100 эпох	74.0% 20 эпох

Оценка LR через кривизну функции потерь



Кривизна показывает, как быстро меняется градиент.

Авторы оценивают её по изменениям весов соседних итераций.

Оценка LR $\approx$ 2–6 для рассматриваемой сети.

Оценка LR вычислена по изменениям весов трёх итераций.

Ограничения исследования

- **Эксперименты:** меньше итераций и выше test accuracy для нескольких наборов данных и архитектур.
- **Механизм:** авторы связывают эффект с шумом и регуляризацией. Полное теоретическое объяснение остаётся открытым.
- Максимальный LR и параметры регуляризации зависят от архитектуры и набора данных.

Выводы статьи

1. LR range test определяет границы циклического расписания.
2. Расписание 1cycle завершается фазой с малым LR.
3. Большой LR требует согласования факторов регуляризации.

В экспериментах статьи 1cycle сокращает число итераций и повышает test accuracy относительно стандартного режима.